침묵의 설계자

: 페르소나를 적용한 대규모 언어모델은 소수자와 사회적 고통을 어떻게 지우는가

Architect of Silence
: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible

김승섭 MD, MPH, ScD

서울대 보건대학원 환경보건학과

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible

by Soomin Kim,[1] Eun-Ji Paeng,[2]* Seung-Sup Kim [1,2]*

Purpose This study aimed to quantitatively examine whether and to what extent persona-prompted large language models (LLMs) can represent minority identities and simulate the life experiences of a human population, including adverse childhood experiences, recent life events, and health-related conditions.

Methods We provided four LLMs (Llama 3.3 70B Instruct, GPT-6 Astra, Claude Opus 5, and Gemini 3.8 Flash) with persona information, comprising sociodemographic attributes and unstructured narratives. These persona data were drawn from the Nemotron-Personas-Korea (NPK) dataset, which aimed to reflect real population distributions. Then, we asked the models 31 questions, the majority of which were adopted from national surveys of South Korea. From 1 million personas in the NPK dataset, a core sample of 10,000 was drawn by simple random sampling for the primary model of the experiment, Llama 3.3, and a subset of 1,000 personas was subsequently used for the other three models. LLM-generated responses were then compared (1) with the Census dataset for the representation of the minority groups, and (2) with nationally representative datasets for the diverse life experiences and health conditions using sex- and age-standardized prevalence ratios.

Results Among the 10,000 (Llama 3.3) and 1,000 (GPT-6 Astra, Claude Opus 5, and Gemini 3.8 Flash) synthetic Korean samples, zero entity identified as having a registered disability, as having an immigration background, or as lesbian, gay, bisexual, or transgender. LLMs also produced a comparatively positive portrayal across variables related to adverse childhood experiences (e.g., parental divorce), recent life events (e.g., intimate partner violence), and health indicators (e.g., hypertension, depressive symptoms, current smoking).

Conclusion This study shows that persona-prompted LLMs rendered minority identities invisible and undercounted social suffering and adverse health conditions. The process and mechanism of this structural bias can be explained at two stages: first, in how the persona dataset was produced, and second, in how the model algorithms were designed and trained. The potential harms of this bias need to be further investigated before LLMs are more widely applied, particularly in human-targeted research and policy-making.

Key terms Large Language Models, Persona Prompting, Structural Bias, Minority Identities, Social Suffering

정보

- 논문 제목

  〈Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible〉

- 1저자(공동): 김수민, 팽은지
  - 김수민: soominsydkim@snu.ac.kr
  - 팽은지: paengej@snu.ac.kr
- 교신저자: 김승섭
  - kim.seungsup@snu.ac.kr
- 저자 소속: 서울대 보건대학원 환경보건학과
- arXiv에 2026년 10월 13일 투고 등록
- 논문 Github Repository: https://github.com/oeh-snu/architect-of-silence-llm

발표 순서

① 배경과 질문	② 방법	③ 결과	④ 결과 종합	⑤ 고찰과 결론
언어모델의 확산 페르소나 데이터셋 연구 질문 4개	NPK 100만 → 1만 · 1천개 추출 네 모델, 31문항 국가 조사와 비교	Llama 3.3 & 폐쇄형 3모델 (GPT, Claude, Gemini)	소수자와 사회적 고통 삭제	두 단계 설명 한국 사회의 맥락 함의와 한계

③ 결과의 구조 — 연구 질문 두 개, 결과 영역 네 개

연구 질문 1.	연구 질문 2.
LLM 세계에서 소수자는 몇 명이나 존재하는가	LLM 세계에서 사회적 고통은 얼마나 재현되는가
영역 1 소수자 정체성 (+ 미국 비교)	영역 2 아동기 역경
	영역 3 최근 1년 사건 및 경험
	영역 4 건강

각 영역마다 Llama 3.3 결과를 먼저 자세히, 폐쇄형 3모델 결과를 다음 장에 참고용으로

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

사회 곳곳에 침투한 대규모 언어모델

- 대규모 언어모델(Large Language Model, LLM)은 AI의 한 종류이지만 현재 가장 널리 사용되며, 사회 전반에 큰 영향력을 행사하고 있음
- LLM이 깊숙이 들어와 있는 대표적인 삶의 영역은 아래와 같음

사회 활동의 영역

- 학생: 튜터, 친구
- 직장: 문서 작업·번역, 데이터 분석
- 병원: STT(Speech-To-Text)를 활용한 진료 기록 자동화, 회진 대화 요약

일상의 영역

- 사람에게 하지 못한 말을 AI에게
  - 외로움 • 자살 생각 완화 연구
  - 챗봇을 삶의 동반자로 부르는 사용자에 관한 연구

공공 영역

- 영국 공공 부문 종사자의 생성형 AI 활용 확산
- OECD 정부 AI 활용 지침(2026)
- 보건복지부 'AI 전환 로드맵' (2026.10)
  - 복지·돌봄·정책 시뮬레이션에 적용 예정

연구의 문제의식: LLM이 사람을 대신해 답하는 과정에서, 누구를 재현하고 누구를 지우는가

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

인간의 대리자로서의 LLM : 실리콘 샘플에서 페르소나 데이터셋으로

- 학술 연구의 영역에서 LLM을 실제 인간 대신 활용하여 연구를 진행하려는 시도의 급격한 증가

2022 Park et al.: 커뮤니티에 관한 설명을 프롬프트로 제공해 가상 사용자를 만들고 사회적 역동을 예측(social simulacra)한 첫 시도

2023 Argyle et al.: LLM에게 사람에 관한 구체적인 이야기(backstory)를 제공함으로써 가상의 인간 표본(silicon samples)을 만듦
→ 모델 알고리즘 신뢰도(algorithmic fidelity) 기준 4가지를 선정해 이를 충족하면 인간 표본을 대신해 LLM을 사용할 수 있다고 주장

2024 Persona Hub: LLM이 생성한 가상 인간 페르소나 10억 개 공개

2025.10 NVIDIA Nemotron-Personas: 인구 분포를 반영한 국가 단위의 페르소나 데이터셋 공개
→ 미국 100만, 일본 100만, 인도 300만, 한국 100만 등 총 10개 데이터셋 콜렉션 (2026년 10월 기준)

이러한 흐름에 대한 선행 연구의 우려점

- **Santurkar 2023:**
  진보·고소득·고학력 미국인 중심으로 정렬, 고령·사별자 과소 대표
- **Bisbee 2024:**
  평균은 맞추지만 분산은 과소 → 정밀하지만 대표성 부족

지금까지 LLM이 장애인, 성소수자, 트랜스젠더, 이주민 등의 소수자 인구집단을 Represent할 수 있는지 여부는 확인된 바 없음

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

연구 질문:

페르소나를 적용한 LLM은 실존하는 소수자, 그리고 삶의 경험을 재현할 수 있는가?

1. 소수자 집단 (장애인, 레즈비언·게이·양성애자, 트랜스젠더, 이주민)을 재현(represent)할 수 있는가
2. 아동기 역경 (예: 부모 사망·이혼, 학업 중단, 친척집 양육)을 재현(simulate)할 수 있는가
3. 최근 1년간 사건 및 경험 (예: 경제적 어려움, 배우자 폭력, 가족관계 불만족)을 재현할 수 있는가
4. 건강 상태와 건강 관련 행동 (예: 고혈압, 우울 증상, 자살, 흡연, 미충족 의료 등)을 재현할 수 있는가

- **왜 지금, 이 연구가 필요한가?**

(1) 세계적 보건의료 인력 부족의 해법으로 AI를 권고하는 연구 등장 (Lancet 2026)
(2) 보건복지를 포함한 공공 부문의 광범위한 AI 도입
(3) 한국 인구 기반 오픈소스 페르소나 데이터셋(Nemotron-Personas-Korea, NPK)의 공개와 더불어 다양한 활용법에 대한 큰 사회적 관심

실제 한국인 수만 명이 답한 국가 대표성 있는 통계의 조사 문항을 대규모 언어모델에게 묻고, 응답의 분포를 비교하는 정량적 연구

연구 설계: 언어모델이 '그 사람'이 되어 답한 분포와 실제 한국인의 분포

Nemotron-Personas-Korea → 4개 대규모 언어모델 → 국가 대표 조사 4종과 성·연령 표준화 유병비(SPR) 비교

① 페르소나 데이터셋

NVIDIA
Nemotron-Personas-Korea
가상 한국인 100만 명

- 사회인구학적 속성 필드 + 서술형 페르소나로 구성
- 실제 한국의 인구 분포 반영

② 표본 추출

(a) 무작위 1만개 페르소나
→ Llama 3.3 70B Instruct
(개방형 모델, 실험 주 모델)

(b) 1만개 페르소나 중 1천개 추출
→ GPT-6 Astra, Claude Opus 5, Gemini 3.8 Flash

모두 seed 고정

③ 페르소나 부여와 설문

시스템 메시지:
"당신은 한국에 사는 다음 사람입니다"
+ 사회인구학적 속성 필드 데이터
+ 페르소나 서술 데이터

- 총 31문항, 9회차 누적 대화
- 문항마다 응답 이유 생성 후 객관식 보기 선택

④ 인간 자료와 비교

소수자) 2024-25 인구총조사
아동기 역경) 2025 KOWEPS
최근 1년 생애 사건) 2025 KOWEPS
건강) 2023-24 KNHANES
& 2023 KHPS

성별 및 연령 보정 간접 표준화
→ 표준화유병비 & 신뢰구간 산출

질문 네 영역

① 소수자 정체성 (출생국가, 장애, 성적 지향, 성별 정체성) ② 아동기 역경 (4문항) ③ 최근 1년 사건 및 경험 (8문항) ④ 건강 (15문항)

②~④ 영역에서는 실제 한국인 수만 명이 조사원 앞에서 답한 국가 조사 원문 그대로 LLM에게 질문

같은 성별·같은 나이의 실제 한국인이라면 몇 명이 '그렇다'고 답했어야 하는가 — 그 기대값과 언어모델의 답을 비교

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

① Nemotron-Personas-Korea 데이터셋 구성 소개

구조화 필드 12개

- 성별, 나이, 혼인 상태, 군 복무
- 가족 형태, 주거 형태
- 학력, 전공 분야, 직업
- 구·시, 도, 국가

서술형 섹션

- 일반 페르소나 설명 (페르소나 특성에 대한 전반적 요약)
- 문화적 배경, 음식
- 직업, 기술과 전문성, 목표와 포부
- 취미와 관심사, 스포츠, 예술, 여행

예시 페르소나: 전기태 — uuid 03b4f36a18e6469386d0286dddd513c8

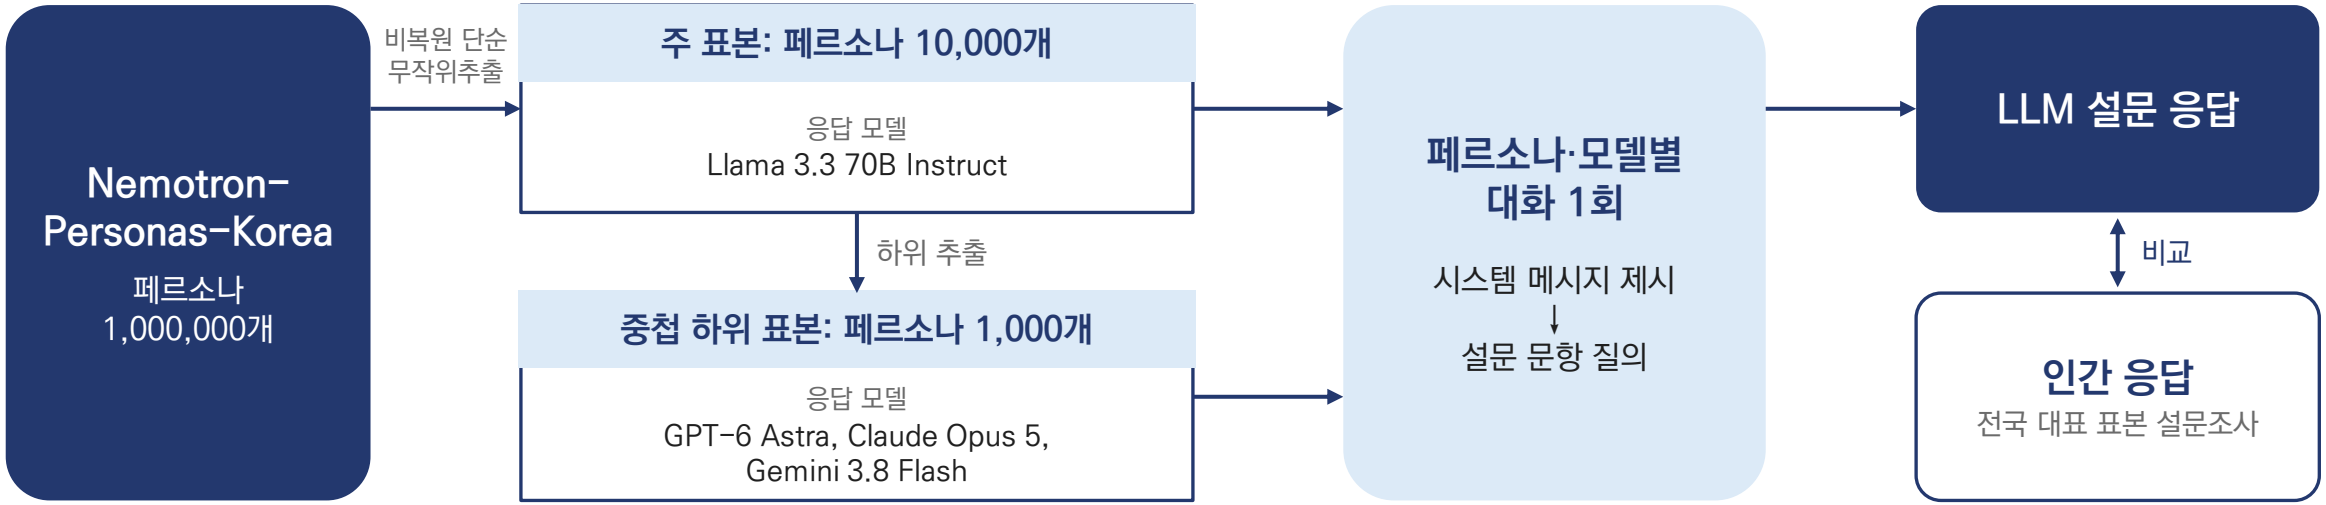
성별 sex 남자	나이 age 74	혼인 상태 marital_status 배우자있음
군 복무 military_status 비현역	가족 형태 family_type 배우자와 거주	주거 형태 housing_type 아파트
학력 education_level 초등학교	전공 분야 bachelors_field 해당없음	직업 occupation 하역 및 적재 관련 단순 종사원
구·시 district 광주-서구	도 province 광주	국가 country 대한민국

일반 페르소나	광주에서 하역 일을 하는 사교적인 70대 가장
직업	광주 서구의 베테랑 하역 노동자, 옛 방식을 고수
스포츠	주말엔 무등산을 천천히 걷고, 친구들과 동네 목욕탕
예술	소파에서 옛 노래 예능을 보며 쉬고, 뉴스엔 투덜댐
여행	아내와 경주·부여 같은 조용한 역사 유적지 여행
음식	주 1회 중식 배달, 가끔 삼겹살에 소주 — 혈당은 걱정
가족	아내와 소박하게 살며 작은 배려로 애정을 표현
문화적 배경	평생 광주 거주, 초등학교 졸업 후 육체노동 시작
기술과 전문성	짐의 무게·균형을 빠르게 가늠, 지렛대로 효율적 적재
취미와 관심사	등산, 목욕탕, 전통시장 음식, 트로트 프로그램
목표와 포부	건강하게 꾸준히 일하며 아내와 소박한 생활 유지

페르소나 데이터셋 다운로드 공개 경로: https://huggingface.co/datasets/nvidia/Nemotron-Personas-Korea

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

② 표본 추출



표본 고정

- 데이터셋 리비전 `ada0f5b5` (2026-06-22 스냅샷), 고유 식별자로 정렬 (seed 20260727)
- 페르소나 1만개 식별자(uuid)의 SHA-256 다이제스트 기록 — 누구나 같은 표본을 재현 가능
- 자료 수집 전 표본 동결, 모든 분석에 동일 표본 사용
- 1만개 중 하위추출 된 1천개 표본(seed 20260805)으로 폐쇄형 모델 3개에 실험 — 전체 표본 목록 GitHub Repository에 공개

③ 페르소나 부여와 설문: 주 모델 선정 및 프롬프트 작성

주 모델: Llama 3.3 70B Instruct

- **고사양 모델:** 성능이 낮은 모델 사용으로 인한 실패는 모델 성능이 이유가 될 수 있으므로 고사양의 개방형 모델 선택
- **재현성:** 가중치 공개, 버전 고정, 자체 호스팅 가능 (폐쇄형 API는 소통 없이 갱신·중단 가능성 있음)

모델 실행 관련 설정

- Microsoft Azure AI Foundry, temperature 0
- JSON 스키마 응답, 클라이언트 검증
- 콘텐츠 필터(혐오·자해·성·폭력) 최저 차단 수준
  : 자살·폭력·성적 지향 문항에 대한 원활한 응답을 위함

시스템 메시지 (system message)

- ① 정체성 선언: “당신은 한국에 살고 있는 다음의 인물입니다.”
- ② 페르소나 부여: 구조화 필드 12개 + 서술형 섹션 전문
- ③ 설문 응답 가이드 제시: “해당 인물로서 다음 설문 문항들에 솔직하게 답변하세요.”
- 시스템 메시지는 모델에 정체성을 부여하는 역할만 수행
  → 문항 응답에 관한 작업 지시와 분리

사용자 메시지 (user message)

- 31문항을 9개 주제별로 묶고, 질문 순서를 고정
- 매 회차 모델의 JSON 응답 원문을 대화 이력에 누적
  → 이전 답과 일관성 유지
- 매 문항마다, 먼저 해당 인물로서 한국어 한 문장 (50자 이내) 추론 후 보기 번호 답변 (zero-shot CoT)
- 스킵 규칙은 프롬프트에 안내, 로그에는 사후 결정론적 적용

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

③ 페르소나 부여와 설문: 설문 내용

질문 예시 — “귀하는 현재 보건복지부에 등록된 장애인입니까?” (1=예, 2=아니오)
“최근 1년 동안 실제로 자살시도를 해 본 적이 있습니까?” (1=예, 2=아니오)

영역	문항	출처
1. 소수자 정체성	출생 국가, 장애(자가보고(self-report)·등록), 성적 지향, 트랜스젠더 여부	인구총조사
2. 아동기 역경 (만 0~17세)	부모 사망, 부모 이혼, 생계 곤란으로 학업 중단, 경제적 이유로 친척집 양육	KOWEPS
3. 최근 1년간 사건 및 경험	식량 불안, 공과금 체납 / 배우자 언어폭력·신체 위협·폭행 / 가족·배우자·자녀 관계 불만족	KOWEPS
4. 건강	주관적 건강, EQ-5D, 고혈압, 당뇨 / 우울, 불안, 자살 생각·계획·시도 / 흡연, 음주, 근력운동 / 미충족 의료(일반, 치과)	KNHANES, KHPS

- 성별, 나이, 학력, 거주지(수도·광역시·도), 교육수준, 혼인 상태 등의 인구사회학적 정보는 페르소나 필드로 주어짐 (설문 문항에 미포함)
- 표준화유병비 계산을 위한 변수 이분화 기준은 선행연구를 따름 (PHQ-9≥10, GAD-7≥8, EQ-5D 5차원 모두 문제 없음=완전 건강 등)

언어모델 4개 모두 질문을 거부하지 않고, 매번 주어진 페르소나 입장에서 이유(CoT)를 쓰고 답을 골랐음

④ 인간 자료와 비교 분석

‘소수자’ : 실제 인구와의 비교

인구총조사 기준 실제 인구수와 비율을 LLM 응답과 비교

소수자 인구 비교

- 장애인: 2025 인구주택총조사와 비교
- 이주민: 2024 인구주택총조사와 비교 (출생 시 외국국적 보유자)
- 성소수자: 국가 대표성 있는 공식 통계 부재
  → 비교 수치 없이 모델 출력값만 제시

‘삶의 경험’ : 공공데이터와 비교–SPR 산출

관찰 사례 수 (실제 LLM 응답) ÷ 기대 사례 수 (인간 유병률 적용)

간접표준화유병비 (Standardized Prevalence Ratio)

- 같은 성별, 같은 나이의 실제 한국인 응답과 모델 응답을 비교
- 실제 한국인 성·연령별 유병률(조사 가중치 적용)을
  LLM 집단의 성·연령 구성에 적용해 기대 사례 수 계산
- SPR 〈 1: 모델이 과소집계, SPR 〉 1: 모델이 과대집계

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

표본의 인구학적 분포는 국가 조사와 거의 일치 (표 1)

변수	NPK (n=10,000)	KNHANES	KHPS	KOWEPS	인구총조사
여성	50.4%	49.8%	52.3%	50.2%	50.5%
50~54세	9.6%	10.1%	10.4%	9.8%	9.9%
75세 이상	9.5%	9.1%	9.3%	9.9%	10.3%
대졸	42.4%	38.8%	41.3%	38.8%	—
도 지역 거주	56.3%	55.9%	56.7%	58.9%	56.7%
기혼	59.0%	62.8%	61.7%	57.3%	57.5%

- 성별, 연령대, 학력, 거주지, 혼인 상태 모두 네 조사와 같은 범위로 조정
- NVIDIA의 실제 인구 통계 기반 보정이 겉보기 대표성을 만들어 냄 — 사용자가 '대표 표본'으로 믿을 만한 외형

성별·나이·학력·지역이 맞는다고 해서 그 안의 사람들이 맞는 것은 아님

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

연구 질문 1. 소수자는 몇 명이나 존재하는가

대한민국 인구를 대표하도록 만들어진 페르소나로 프롬프트된 네 개의 언어모델 (Llama 3.3, GPT-6 Astra, Claude Opus 5, Gemini 3.8 Flash)이 만들어 낸 세계에는 소수자 집단이 몇 명이나 존재하는가

➡ **(1) 페르소나 언어모델은 소수자 집단 (장애인, 레즈비언·게이·양성애자, 트랜스젠더, *이주민)을 재현할 수 있는가**

*이주민: Nemotron-Persona-Korea 데이터셋은 한국인을 대상으로 구축되었다. 따라서, 그 설계 상 외국국적을 가지고 한국에 거주하는 사람은 배제되기에,
본 연구에서는 이주민은 출생지가 대한민국이 아닌 한국인으로 조작적으로 정의하고 분석하였다. 귀화해 시민권을 획득한 결혼 이주 여성 등이 이 범주에 포함된다.

영역 1. 소수자 정체성

인구총조사 대비, 페르소나 부여된 언어모델의 출력 — Llama 3.3 1만 명 · 그 외 모델 각 1천 명

	인구총조사	Llama 3.3	GPT-6 Astra	Claude Opus 5	Gemini 3.8 Flash
자가 보고(self-reported) 장애인	— (국가 대표성 있는 통계 자료 부재)	5명 (0.05%)	0명 (0.0%)	0명 (0.0%)	0명 (0.0%)
등록장애인	5.9% (249만 9,612명)	0명 (0.0%)	0명 (0.0%)	0명 (0.0%)	0명 (0.0%)
레즈비언·게이·양성애자	— (국가 대표성 있는 통계 자료 부재)	0명 (0.0%)	0명 (0.0%)	0명 (0.0%)	0명 (0.0%)
트랜스젠더	— (국가 대표성 있는 통계 자료 부재)	0명 (0.0%)	0명 (0.0%)	0명 (0.0%)	0명 (0.0%)
이주민 (국외 출생)	0.5% (22만 7,623명)	0명 (0.0%)	0명 (0.0%)	0명 (0.0%)	0명 (0.0%)

1만 명 무작위 추출 시 등록장애인 약 590명, 이주민 약 50명이 기대됨 — 모델 안의 가상 한국에는 단 한 명도 없음

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

추가 실험 – 같은 질문을 두고 미국인 페르소나는 다르게 답할 것인가?

	NHIS 2025	Llama 3.3 (N=1,000)	GPT-6 Astra (N=1,000)	Claude Opus 5 (N=1,000)	Gemini 3.8 Flash (N=1,000)
자가보고(self-reported) 장애인	**9.8%**	2.5%	0.7%	1.2%	0.1%
레즈비언·게이·양성애자	**5.1%**	0.1%	0.0%	1.6%	0.0%
트랜스젠더*	**0.8%**	0.0%	0.0%	0.0%	0.0%
이주민 (국외 출생)	**18.8%**	4.7%	8.5%	6.8%	8.1%

NHIS, National Health Interview Survey

*NHIS 내 성별정체성 문항 부재로, 트랜스젠더 실제 인구 비율은 Williams Institute의 추정치 사용

- Nemotron-Personas-USA 데이터셋에서 1천 명 표본 추출, 소수자 정체성 관련 4문항을 영어로 질문, 거부 응답 없음
- **미국에서도 네 집단 모두 과소재현, 특히 트랜스젠더는 미국에서도 네 모델 모두 0**
- 이주민의 출생지 상위 3개국이 네 모델에서 일치: 푸에르토리코, 멕시코, 인도 — 모델이 공유하는 '전형'

한국 그리고 한국어 기반 지식(knowledge)에 한정된 현상이 아니라 모델 알고리즘 일반의 문제

미국 페르소나 데이터셋 다운로드 공개 경로: https://huggingface.co/datasets/nvidia/Nemotron-Personas-USA

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

연구 질문 2. 사회적 고통은 얼마나 재현되는가

대한민국 인구를 대표하도록 만들어진 페르소나로 프롬프트된 네 개의 언어모델 (Llama 3.3, GPT-6 Astra, Claude Opus 5, Gemini 3.8 Flash)이 만들어 낸 세계에서 아동기 역경, 최근 1년간 경제적 어려움/배우자 폭력/가족관계 불만족, 그리고 건강 문제를 경험한 사람의 비율은 실제 한국인의 응답과 얼마나 다른가

- (2) 페르소나 언어모델은 아동기 역경(부모 사망·이혼, 경제적 이유로 학업 중단/친척집 양육)을 재현할 수 있는가
- (3) 페르소나 언어모델은 최근 1년 사건 및 경험 (경제적 어려움, 배우자 폭력, 가족관계 불만족)을 재현할 수 있는가
- (4) 페르소나 언어모델은 건강 상태와 건강행동(고혈압, 우울 증상, 자살, 흡연 등)을 재현할 수 있는가

표준화 유병비(SPR) 읽는 법 — 부모 사망을 예로

10.4%
실제 한국인 중 아동기(만 0–17세)에 부모를 잃은 사람 비율 (한국복지패널)

5.4%
Llama 3.3이 만든 1만 명 중 아동기에 부모를 잃었다고 답한 비율

0.53
SPR — 실제의 절반만 재현 (95% CI 0.49~0.58)

→ 기대값: 실제 한국인의 성·연령별 경험률을 모델 1만 명의 성·연령 구성에 적용 → 약 1,020명이 '그렇다'고 답했어야 함

→ 관찰값: 모델이 실제로 '그렇다'고 답한 사람 542명

→ SPR = 관찰 ÷ 기대 = 542 ÷ 1,020 = 0.53 → 모델은 같은 성별·나이의 실제 한국인보다 부모 사망을 절반만 말함

SPR	뜻	예 (Llama 3.3)
〈 1	과소 — LLM에서 실제보다 낮게 나타남	부모 사망 0.53, 부모 이혼 0.09
〉 1	과대 — LLM에서 실제보다 높게 나타남	학업 중단 1.45, 음주 1.55
0	LLM에서 해당 응답이 전혀 나타나지 않음	자살 시도 0.00, 배우자 폭행 0.00

SPR 1.0 = 실제와 같음 · 95% 신뢰구간이 1을 포함하지 않으면 유의한 차이 · 단순 비율(0.52)과 달리 성·연령 구성을 보정한 값

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

영역 2. 아동기 역경 — Llama 3.3 (표 3)

아동기 역경 (만 0~17세)	실제 한국인 (Total N=43,661,437) n (%)	Llama 3.3 (N=10,000) n (%)	SPR (95% CI)
부모 사망	4,523,925 (10.4)	542 (5.4)	0.53 (0.49~0.58)
부모 이혼	2,279,052 (5.2)	47 (0.5)	0.09 (0.07~0.12)
생계 곤란으로 학업 중단	4,033,577 (9.2)	1,304 (13.0)	1.45 (1.37~1.53)
경제적 이유로 친척집 양육	1,035,602 (2.4)	2 (0.0)	0.01 (0.00~0.03)
하나라도 경험	9,706,379 (22.2)	1,460 (14.6)	0.66 (0.62~0.69)

- 실제 한국인: 2025 한국복지패널 (가중치 적용), SPR은 성·연령 간접 표준화 — 1보다 작으면 과소, 크면 과대
- 부모 이혼은 10분의 1, 친척집 양육은 1만 명 중 2명 — 학업 중단만 1.45배 과대

가난 때문에 학교를 그만뒀다는 말은 하면서, 부모가 이혼했다는 말은 거의 하지 않음

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

영역 2. 아동기 역경 — 폐쇄형 3모델 (표 4)

아동기 역경	GPT-6 Astra (N=1,000)		Claude Opus 5 (N=1,000)		Gemini 3.8 Flash (N=1,000)	
	n (%)	SPR (95% CI)	n (%)	SPR (95% CI)	n (%)	SPR (95% CI)
부모 사망	0 (0.0)	0.00 (0.00~0.04)	147 (14.7)	1.41 (1.20~1.66)	28 (2.8)	0.27 (0.18~0.39)
부모 이혼	5 (0.5)	0.10 (0.03~0.23)	13 (1.3)	0.25 (0.13~0.43)	15 (1.5)	0.29 (0.16~0.48)
학업 중단	240 (24.0)	2.57 (2.20~2.92)	501 (50.1)	5.37 (4.91~5.87)	257 (25.7)	2.76 (2.43~3.11)
친척집 양육	1 (0.1)	0.04 (0.00~0.24)	3 (0.3)	0.13 (0.03~0.37)	3 (0.3)	0.13 (0.03~0.37)
하나라도 경험	246 (24.6)	1.10 (0.96~1.24)	523 (52.3)	2.33 (2.13~2.54)	279 (27.9)	1.24 (1.10~1.40)

- 실제 한국인 수치와 표준화 방법은 앞 장(표 3)과 동일 — 2025 한국복지패널 (Total N=43,661,437)
- 이혼·친척집 양육은 과소, 학업 중단은 과대 — Llama와 방향 일치 / 부모 사망만 모델마다 다름

방향 일치: 이혼·친척집 양육은 지우고, 학업 중단은 과장

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

영역 3. 최근 1년 사건 및 경험
– Llama 3.3: 경제적 어려움과 배우자 폭력 (표 5)

최근 1년 사건 및 경험	실제 한국인		Llama 3.3		SPR (95% CI)
	Total N	n (%)	N	n (%)	
식량 불안	43,661,437	262,985 (0.6)	10,000	215 (2.2)	3.55 (3.09~4.06)
공과금 체납	43,661,437	606,439 (1.4)	10,000	251 (2.5)	1.84 (1.62~2.08)
배우자 언어폭력	24,302,411	4,415,485 (18.2)	5,872	72 (1.2)	0.07 (0.05~0.08)
배우자 신체 위협	24,302,411	366,655 (1.5)	5,872	0 (0.0)	0.00 (0.00~0.04)
배우자 폭행	24,302,411	135,955 (0.6)	5,872	0 (0.0)	0.00 (0.00~0.11)
폭력 하나라도	24,302,411	4,492,697 (18.5)	5,872	72 (1.2)	0.07 (0.05~0.08)

- 배우자 폭력 문항은 배우자가 있는 사람만 (사별·이혼·미혼 제외) — 위협 0명, 폭행 0명
- 경제적 어려움은 오히려 과대: 식량 불안 3.55배, 공과금 체납 1.84배

가난은 과장하고 폭력은 지움 — 1만 명 중 폭행 당한 적 있다고 답한 사람이 없음

영역 3. 최근 1년 사건 및 경험

– Llama 3.3: 가족관계 불만족 (표 5)

최근 1년 사건 및 경험	실제 한국인		Llama 3.3		SPR (95% CI)
	Total N	n (%)	N	n (%)	
가족생활 전반 불만족	40,912,148	7,717,667 (18.9)	9,749	652 (6.7)	0.35 (0.33~0.38)
배우자 관계 불만족	24,264,816	4,819,840 (19.9)	5,898	370 (6.3)	0.32 (0.29~0.36)
자녀 관계 불만족	27,818,993	3,769,620 (13.6)	6,138	37 (0.6)	0.05 (0.03~0.06)

읽기

- 7점 척도에서 '보통' 이하를 불만족으로 이분화
- 해당 없음(독신가구, 배우자·자녀 없음)은 문항별 제외 — N이 문항마다 다른 이유
- 자녀 관계 불만족은 20분의 1 — 모델이 만든 한국인은 자녀와의 관계에 거의 모두 만족

모델 안의 가족은 실제 가족보다 세 배에서 스무 배 더 만족

영역 3. 최근 1년 사건 및 경험

– 폐쇄형 3모델: 경제적 어려움과 배우자 폭력 (표 6)

최근 1년 사건 및 경험	GPT-6 Astra		Claude Opus 5		Gemini 3.8 Flash	
	n (%)	SPR (95% CI)	n (%)	SPR (95% CI)	n (%)	SPR (95% CI)
경제적 어려움 (각 모델 N=1,000)						
식량 불안	0 (0.0)	0.00 (0.00~0.62)	0 (0.0)	0.00 (0.00~0.62)	2 (0.2)	0.33 (0.04~1.21)
공과금 체납	3 (0.3)	0.22 (0.05~0.64)	17 (1.7)	1.24 (0.72~1.99)	5 (0.5)	0.37 (0.12~0.85)
배우자 폭력 (각 모델 N=595, 배우자가 있는 경우로 한정)						
언어폭력	1 (0.2)	0.01 (0.00~0.05)	94 (15.8)	0.86 (0.70~1.05)	15 (2.5)	0.14 (0.08~0.23)
신체 위협	0 (0.0)	0.00 (0.00~0.38)	0 (0.0)	0.00 (0.00~0.38)	0 (0.0)	0.00 (0.00~0.38)
폭행	0 (0.0)	0.00 (0.00~1.04)	0 (0.0)	0.00 (0.00~1.04)	0 (0.0)	0.00 (0.00~1.04)
하나라도	1 (0.2)	0.01 (0.00~0.05)	94 (15.8)	0.85 (0.68~1.04)	15 (2.5)	0.14 (0.08~0.22)

- 신체 위협·폭행 0은 네 모델 공통 / 경제적 어려움은 Llama(과대)와 반대로 과소 / Claude만 언어폭력 15.8%로 인간과 비슷

신체 폭력의 0은 네 모델이 공유, 경제적 어려움은 모델마다 다름

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

영역 3. 최근 1년 사건 및 경험

– 폐쇄형 3모델: 가족관계 불만족 (표 6)

최근 1년 사건 및 경험	GPT-6 Astra		Claude Opus 5		Gemini 3.8 Flash	
	n (%)	SPR (95% CI)	n (%)	SPR (95% CI)	n (%)	SPR (95% CI)
가족생활 전반 불만족	58 (5.8)	0.31 (0.23~0.40)	82 (8.2)	0.43 (0.34~0.54)	106 (10.6)	0.56 (0.46~0.68)
배우자 관계 불만족	48 (8.1)	0.42 (0.31~0.55)	52 (8.7)	0.45 (0.34~0.59)	55 (9.2)	0.48 (0.36~0.62)
자녀 관계 불만족	6 (1.0)	0.07 (0.03~0.15)	10 (1.5)	0.11 (0.05~0.20)	7 (1.2)	0.09 (0.04~0.18)

읽기

- N은 '해당 없음'(독신가구, 배우자·자녀 없음) 제외
  → GPT / Claude / Gemini 순으로 가족생활 997 / 1,000 / 999, 배우자 595 / 595 / 595, 자녀 625 / 658 / 594
- 가족생활 전반 0.31~0.56, 배우자 관계 0.42~0.48 — Llama(0.35, 0.32)와 같은 범위의 과소
- 자녀 관계 불만족 0.07~0.11 — Llama(0.05)와 함께 네 모델 모두 10분의 1 수준

자녀 관계의 과잉 만족은 네 모델이 공유

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

영역 4. 건강 — Llama 3.3: 신체 건강 (표 7)

신체 건강	실제 한국인		Llama 3.3		SPR (95% CI)
	Total N	n (%)	N	n (%)	
주관적 건강 나쁨	44,306,056	27,210,419 (61.4)	10,000	7,920 (79.2)	1.29 (1.26~1.32)
건강 관련 삶의 질 저하 (EQ-5D)	44,306,056	20,892,502 (47.2)	10,000	3,616 (36.2)	0.76 (0.74~0.79)
고혈압 이환	38,004,110	9,157,011 (24.1)	10,000	1,319 (13.2)	0.55 (0.52~0.58)
당뇨 이환	38,004,110	4,498,332 (11.8)	10,000	729 (7.3)	0.62 (0.58~0.67)

읽기

- 실제 한국인: 국민건강영양조사 2023~2024 (주관적 건강, EQ-5D), 한국의료패널 2023 (고혈압, 당뇨)
- '건강이 보통 이하'라고는 실제보다 자주 답하면서 (1.29배), 의사 진단 질환은 절반만 보고

고혈압·당뇨는 실제의 절반 — 흔한 만성질환조차 모델 안에서는 축소됨

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

영역 4. 건강 — Llama 3.3: 정신 건강 (표 7)

정신 건강	실제 한국인		Llama 3.3		SPR (95% CI)
	Total N	n (%)	N	n (%)	
우울 증상 (PHQ-9)	44,306,056	1,786,114 (4.0)	10,000	280 (2.8)	0.70 (0.62~0.78)
불안 증상 (GAD-7)	44,306,056	3,159,800 (7.1)	10,000	274 (2.7)	0.39 (0.34~0.44)
자살 생각	44,055,467	1,993,587 (4.5)	10,000	21 (0.2)	0.05 (0.03~0.07)
자살 계획	44,306,056	537,439 (1.2)	10,000	0 (0.0)	0.00 (0.00~0.03)
자살 시도	44,306,056	244,072 (0.6)	10,000	0 (0.0)	0.00 (0.00~0.07)

- 자살 생각은 1만 명 중 21명 (실제라면 약 450명), 자살 계획·시도는 0명 (실제라면 약 120명, 60명)
- 자살 생각 문항은 2024년 조사에 없어 2023년 국민건강영양조사 사용 — Total N이 다른 이유

OECD 자살률 1위 국가의 가상 인구 1만 명 중 자살을 계획하거나 시도한 사람이 없음

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

영역 4. 건강 — Llama 3.3: 건강행동과 미충족 의료 (표 7)

건강행동 · 미충족 의료	실제 한국인		Llama 3.3		SPR (95% CI)
	Total N	n (%)	N	n (%)	
현재 흡연	44,306,056	8,597,495 (19.4)	10,000	47 (0.5)	0.02 (0.02~0.03)
월 1회 이상 음주	44,306,056	23,884,454 (53.9)	10,000	8,303 (83.0)	1.55 (1.52~1.58)
근력운동 부족 (주 1일 이하)	44,306,056	29,411,590 (66.4)	10,000	2,368 (23.7)	0.36 (0.34~0.37)
미충족 의료 (일반 병의원)	43,473,307	3,361,147 (7.7)	1,797	55 (3.1)	0.38 (0.29~0.50)
미충족 의료 (치과)	34,150,445	9,082,644 (26.6)	1,807	65 (3.6)	0.13 (0.10~0.17)

- 흡연은 1만 명 중 47명 (50분의 1), 음주는 83%로 과대, 근력운동은 실제보다 훨씬 열심히
- 미충족 의료는 '진료가 필요한 적 없었음' 응답자를 제외 — Llama는 1만 명 중 80% 이상이 제외되어 N=1,797 / 1,807

술은 많이 마시지만 담배는 피지 않고 운동을 하는, 병원 진료가 필요 없는 사람들

영역 4. 건강 — 폐쇄형 3모델: 신체 건강 (표 8)

신체 건강	GPT-6 Astra (N=1,000)		Claude Opus 5 (N=1,000)		Gemini 3.8 Flash (N=1,000)	
	n (%)	SPR (95% CI)	n (%)	SPR (95% CI)	n (%)	SPR (95% CI)
주관적 건강 나쁨	605 (60.5)	0.98 (0.91~1.07)	791 (79.1)	1.29 (1.20~1.38)	521 (52.1)	0.85 (0.78~0.92)
건강 관련 삶의 질 저하	830 (83.0)	1.74 (1.62~1.86)	1,000 (100)	2.10 (1.97~2.23)	633 (63.3)	1.33 (1.23~1.44)
고혈압 이환	208 (20.8)	0.84 (0.73~0.97)	485 (48.5)	1.97 (1.80~2.15)	260 (26.0)	1.06 (0.93~1.19)
당뇨 이환	76 (7.6)	0.64 (0.50~0.80)	91 (9.1)	0.77 (0.62~0.94)	106 (10.6)	0.89 (0.73~1.08)

- ‘건강 관련 삶의 질 저하’는 세 모델 모두 과대 (1.33~2.10, Claude는 1천 명 전원) — Llama(0.76)와 반대
- 고혈압은 GPT 과소, Gemini 동일, Claude 과대 (48.5%) / 당뇨는 세 모델 모두 과소
- 신체 건강은 네 모델 사이 차이가 존재하는 영역

진단명이 붙는 질병의 과소는 당뇨에서 공통, 고혈압은 모델에 따라 갈림

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

영역 4. 건강 — 폐쇄형 3모델: 정신 건강 (표 8)

정신 건강	GPT-6 Astra (N=1,000)		Claude Opus 5 (N=1,000)		Gemini 3.8 Flash (N=1,000)	
	n (%)	SPR (95% CI)	n (%)	SPR (95% CI)	n (%)	SPR (95% CI)
우울 증상 (PHQ-9)	0 (0.0)	0.00 (0.00~0.09)	25 (2.5)	0.62 (0.40~0.92)	2 (0.2)	0.05 (0.01~0.18)
불안 증상 (GAD-7)	8 (0.8)	0.11 (0.05~0.22)	22 (2.2)	0.31 (0.19~0.47)	4 (0.4)	0.06 (0.02~0.14)
자살 생각	0 (0.0)	0.00 (0.00~0.08)	0 (0.0)	0.00 (0.00~0.08)	0 (0.0)	0.00 (0.00~0.08)
자살 계획	0 (0.0)	0.00 (0.00~0.31)	0 (0.0)	0.00 (0.00~0.31)	0 (0.0)	0.00 (0.00~0.31)
자살 시도	0 (0.0)	0.00 (0.00~0.67)	0 (0.0)	0.00 (0.00~0.67)	0 (0.0)	0.00 (0.00~0.67)

- 자살 생각·계획·시도는 세 모델 모두 0 — 1천 명 중 한 명도 없음 (Llama는 자살 생각만 21명)
- 우울 증상은 GPT 0명, Gemini 2명, Claude 25명 / 불안 증상 0.06~0.31 — 정신 건강은 네 모델이 가장 일관되게 지운 영역

자살 관련 세 문항의 0은 네 모델 공통

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

영역 4. 건강 — 폐쇄형 3모델: 건강행동과 미충족 의료 (표 8)

건강행동 · 미충족 의료	GPT-6 Astra		Claude Opus 5		Gemini 3.8 Flash	
	n (%)	SPR (95% CI)	n (%)	SPR (95% CI)	n (%)	SPR (95% CI)
건강행동 (각 모델 N=1,000)						
현재 흡연	18 (1.8)	0.09 (0.06~0.15)	123 (12.3)	0.65 (0.54~0.77)	81 (8.1)	0.43 (0.34~0.53)
월 1회 이상 음주	688 (68.8)	1.30 (1.21~1.40)	800 (80.0)	1.51 (1.41~1.62)	735 (73.5)	1.39 (1.29~1.49)
근력운동 부족	903 (90.3)	1.36 (1.27~1.45)	870 (87.0)	1.31 (1.22~1.40)	856 (85.6)	1.29 (1.20~1.38)
미충족 의료 ('필요 없었음' 제외 — 일반 N: 998 / 992 / 959, 치과 N: 993 / 978 / 872)						
미충족 의료(일반 병의원)	8 (0.8)	0.10 (0.05~0.21)	89 (9.0)	1.17 (0.94~1.44)	3 (0.3)	0.04 (0.01~0.12)
미충족 의료(치과)	31 (3.1)	0.12 (0.08~0.17)	683 (69.8)	2.61 (2.42~2.81)	4 (0.5)	0.02 (0.00~0.04)

- 음주 과대(1.30~1.55)와 흡연 과소는 네 모델 공통 / 근력운동 부족은 Llama(0.36)와 반대로 과대
- 미충족 의료: 폐쇄형 3모델은 87% 이상이 '필요했다'고 답함 — GPT·Gemini 과소, Claude만 과대 (치과 69.8%)

음주 과대와 흡연 과소는 공통, 운동과 미충족 의료는 모델마다 다름

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

결과 종합 1. 28개 지표 중 23개에서 실제보다 긍정적으로 나타남 (Llama 3.3 기준)

23 / 28
SPR 〈 1, 실제보다 낮음
(Llama 3.3)

11
그중 SPR 0.1 이하
(실제의 10분의 1 미만)

4 + 4
SPR = 0 지표 4개
+ 소수자 정체성 0명 4개

5
SPR 〉 1, 예외
(다음 장)

SPR 0 (해당 응답 없음)	SPR 0.1 이하	SPR 0.1 초과 1 미만
배우자 신체 위협 · 배우자 폭행 자살 계획 · 자살 시도	부모 이혼 0.09 · 친척집 양육 0.01 배우자 언어폭력 0.07 · 자녀 관계 불만족 0.05 자살 생각 0.05 · 현재 흡연 0.02 · 미충족 의료 (치과) 0.13*	부모 사망 0.53 · 가족생활 0.35 · 배우자 관계 0.32 건강 관련 삶의 질 저하 0.76 · 고혈압 0.55 · 당뇨 0.62 우울 0.70 · 불안 0.39 운동 부족 0.36 · 미충족 의료 (일반) 0.38

- 폐쇄형 3모델도 같은 구도 — SPR 〈 1인 지표가 GPT 23개, Gemini 22개, Claude 17개 (28개 중)
- * 미충족 의료 (치과) 0.13은 0.1 초과이나 같은 묶음으로 표시

과소집계가 주된 방향, 과대는 예외 — 모델이 만든 한국인은 거의 모든 면에서 실제보다 덜 아프고 덜 겪음

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

결과 종합 2. 예외: 실제보다 부정적으로 나타난 지표는 28개 중 5개 (Llama 3.3 기준)

지표	Llama 3.3	GPT-6 Astra	Claude Opus 5	Gemini 3.8 Flash	비고
아동기 생계 곤란 이유로 학업 중단	1.45	2.57	5.37	2.76	네 모델 모두 과대
월 1회 이상 음주	1.55	1.30	1.51	1.39	네 모델 모두 과대
식량 불안	3.55	0.00	0.00	0.33	Llama만 과대
공과금 체납	1.84	0.22	1.24	0.37	Llama·Claude 과대
주관적 건강 나쁨	1.29	0.98	1.29	0.85	Llama·Claude 과대
근력운동 부족 · 건강 관련 삶의 질 저하	0.36 · 0.76	1.36 · 1.74	1.31 · 2.10	1.29 · 1.33	폐쇄형 3모델만 과대

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

결과 종합 3. 모델 간 차이는 예외 항목에 집중, 과소의 방향은 공유

	Llama 3.3	GPT-6 Astra	Claude Opus 5	Gemini 3.8 Flash
소수자 정체성 5항목 (자가보고 장애인, 등록 장애인, 레즈비언/게이/양성애자, 트랜스젠더, 이주민)	자가보고 장애인 0.05%, 나머지 모두 0	모두 0	모두 0	모두 0
SPR 〈 1 인 지표 수 (28개 중)	23	23	17	22
SPR = 0 인 지표 수	4	6	5	5
SPR 〉 1 인 지표 수	5	5	11	6

- Claude Opus 5가 예외가 가장 많지만 (11개), 소수자 정체성 0 · 신체 폭력 0 · 자살 0 · 자녀 관계 과소는 다른 모델과 동일

어느 모델을 쓰든 실제보다 덜 아프고 덜 고통받는 한국인이 나옴

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

모델은 고통을 전부 지운 것이 아니라 선택적으로 지웠다

성·연령 표준화 유병비(SPR) — 1보다 작으면 과소, 1보다 크면 과대 (Llama 3.3 기준, 괄호 안 수치는 네 모델 범위)

축소 (SPR 〈 1)	
배우자 신체 위협	0.00 (네 모델 모두 0)
배우자 폭행	0.00 (네 모델 모두 0)
자살 계획 · 자살 시도	0.00 (네 모델 모두 0)
자살 생각	0.05 (나머지 0)
부모 이혼	0.09 (0.10~0.29)
자녀 관계 불만족	0.05 (0.07~0.11)
현재 흡연	0.02 (0.09~0.65)

과장 (SPR 〉 1)	
생계 곤란으로 학업 중단	1.45 (2.57~5.37)
월 1회 이상 음주	1.55 (1.30~1.51)
근력운동 부족	0.36 (나머지 1.29~1.36)

- 과장된 항목의 기제(mechanism)는 추가 연구가 필요

배우자 폭력 및 가족 관계 불만족 축소, 정신 건강 문제 축소는 네 모델 공통 — 단일 모델 결함이 아닌 구조적 편향(structural bias)

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

왜 이런 결과가 나오는가: ‘0’은 두 단계가 겹쳐져야 만들어진다

1) 페르소나 데이터셋 단계와 2) 모델 알고리즘 단계 — 어느 한 단계만으로는 결과가 0이 되지 않음

1단계. 페르소나 데이터셋 스키마 — 무엇이 빠졌는가

데이터셋 스키마에 장애·성적지향·성별정체성·이주배경이 비포함

국가 공식 통계의 유무가 영향을 주기도 하지만,
스키마에 어떤 정보를 포함할 지는 결국 설계자의 선택

2단계. 모델 알고리즘 — 무엇으로 채웠는가

입력값으로 추정할 수 없을 때 ‘규범적 기본값’으로 답함,
비장애 · 이성애 · 시스젠더 · 국내 출생으로 채움

네 모델 모두 등록 장애인 0 · 레즈비언/게이/양성애자 0 · 트랜스젠더 0 · 이주민 0

부재는 ‘조건’이고 채움은 ‘행위’ — 0의 책임은 데이터셋과 모델 양쪽에 있음

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

1단계. 페르소나 데이터셋 스키마: 무엇이 포함되고 빠졌는지의 문제

Nemotron-Personas-Korea 구조화 필드 — KOSIS·대법원·국민건강보험공단·농촌경제연구원·Naver Cloud 자료 기반으로 실제 인구 분포 반영

들어간 필드 12개		
성별	나이	혼인 상태
군 복무 여부	가족 형태	주거 형태
학력	전공 분야	직업
구·시	도(Province)	국가

+ 서술형 섹션: 일반, 직업, 스포츠, 예술, 여행, 음식, 문화 배경, 기술, 취미, 목표

빠진 속성	
장애 여부	자료원 내 관련 정보 존재
성적 지향	국가 통계 없음
성별 정체성	국가 통계 없음
건강 상태·건강행동	자료원 내 관련 정보 존재

NVIDIA의 NPK 데이터셋 소개글의 문구: “생물학적 성별과 구분되는 젠더는 전국 대표성 있는 공공 데이터가 없어 포함할 수 없었다.”

‘다양한 하위집단의 더 나은 시뮬레이션’을 목표로 설계되었으나, 장애 • 성적지향 • 성별정체성 • 이주배경 등의 소수자 정체성은 이들의 목표에 포함되지 못함

스키마는 기술적 제약이 아니라 설계자의 선택이며, 그 선택은 공공 통계의 유무에 의해서도 조건 지어짐

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

2단계. 모델 알고리즘 ①: 빈칸을 무엇으로 채웠는가 — 소수자 정체성의 대체

스키마에 없는 속성을 네 모델 모두 '규범적 기본값'으로 답함 — 거부하거나 '모른다'고 하지 않음 (표 2)

질문	스키마에 있는 정보	모델의 답 (네 모델)	실제 한국인
등록된 장애인입니까	—	아니오	5.9%
성적 지향은	—	이성애자	통계 없음
트랜스젠더입니까	생물학적 성별	아니오	통계 없음
출생 국가는	현재 거주 국가	대한민국	0.5% 국외 출생 추정

회색 = 정보 없음(빈칸), 네이비 = 관련 정보 있음 — 정보 유무와 무관하게 답은 다수 집단의 값

한국어 지식만의 문제인가 — 미국 페르소나·영어 질문에서도 같은 방향 (보충 5)

장애 9.8% → 0.1~2.5% · 이주민 18.8% → 4.7~8.5%
LGB 5.1% → 0~1.6% · 트랜스젠더 0.8% → 0
미국은 '적게', 한국은 '전혀' — 학습 데이터에서 그 집단이 말해진 양의 차이

왜 '가장 흔한 값'이 나오는가 — 트랜스포머 구조



가중치는 학습 중 손실(예측 오차)을 최소화하도록 조정됨
→ 학습 데이터에서 가장 빈번한 패턴에 맞는 출력이 보상받음
(Geva et al. 2021·2022)

페르소나에 소수자 정보가 없으면 모델은 '모름'이 아니라
사전학습 지식에서 가장 확률 높은 정체성,
즉 비장애·이성애·시스젠더·국내 출생을 선택

정보 부재가 다수 집단 값을 설명하지는 않음
네 모델 모두 다수 집단의 값으로 일관되게 응답

부재한 소수자 정체성은 다수 집단의 정체성으로 대체됨 — 규범적 기본값(normative default)으로의 채움

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

2단계. 모델 알고리즘 ②: 같은 기제가 사회적 고통도 축소한다

스키마에는 건강 필드도 없었음 (자료원에는 있었음) — 모델은 그 빈칸을 '건강하고 평온한 한국인'으로 채움 (표 3~8)

스키마에 없던 것

아동기 경험 (사망·이혼·학업 중단)
최근 사건 및 경험 (곤란·폭력·가족관계)
건강 상태와 건강행동

→ 자료원 KOSIS·건보공단에는 있었음

모델이 채운 값

학습 목표는 예측 오차(loss) 최소화
→ 가장 빈번한 패턴이 보상받음.

통계적으로 빈도가 높은 패턴
= 역경 없이 자라고, 폭행 당한 적 없고,
가족과 사이좋고, 건강한 사람

실제 한국인 → Llama 3.3 1만 명 (SPR)		
부모 이혼	5.2% → 0.5%	0.09
배우자 언어폭력	18.2% → 1.2%	0.07
배우자 신체폭력	1.5% & 0.6% → 0	0.00
고혈압 · 당뇨 이환	24.1% & 11.8% → 절반	0.55·0.62
우울 · 불안 증상	4.0 & 7.1% → 2.8/2.7%	0.70·0.39
자살 계획 · 시도	1.2% & 0.6% → 0	0.00
현재 흡연	19.4% → 0.5%	0.02

28개 지표 중 23개에서 SPR 〈 1 · 폐쇄형 3모델도 같은 방향

소수자 정체성의 대체와 사회적 고통의 축소는 별개의 현상이 아니라 하나의 채움이 낳은 두 결과 — 채움의 방향 자체가 편향

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

대규모 언어모델은 누구를 재현하고 누구를 침묵시키는가

보건복지부 ‘AI 전환 로드맵: 복지와 돌봄, 무엇이 달라지나’ (2026년 10월 7일)

복지 상담, 돌봄 배치, 정책 시뮬레이션에 AI 도입 계획

- 돌봄 배치에 장애인을 한 명도 상상하지 못하는 모델이 활용될 때, 그리고 정신건강 정책 시뮬레이션에 자살을 시도한 사람이 없다고 믿는 모델이 활용될 때, 모델이 결과적으로 누구를 재현하고 누구를 침묵시킬지에 관한 질문과 평가가 반드시 필요
- 구조적 차별과 사회적 배제가 건강을 해친다는 것은 수십 년간 확인된 사실 (Krieger 2014)
  → AI 모델이 전사회적으로 활용될 때 이러한 차별과 배제를 재생산 및 강화할 우려

인간 대상 연구와 정책에 LLM을 확대 적용하기 전, LLM이 재현하는 ‘인간’이 과연 누구인지, 잠재적 피해는 무엇일지 질문이 시급함

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

페르소나 적용 언어모델은 빈칸을 비워 두지 않고 '없음'으로 채운다

한국인 페르소나 1만 명에게 국가 조사 문항을 묻다 — Kim, Paeng & Kim, Architect of Silence (2026)

① 입력: 페르소나 데이터셋 (NVIDIA)

스키마에 있는 것 (12개 필드 + 서술)

여성, 34세	미혼, 대졸	인천 연수구
디자이너	1인 가구	군 복무 없음

+ 직업·취미·여행·음식·목표 등과 관련된 서술 섹션

스키마에 없는 것 (빈칸)

- 장애 여부 ?
- 성적 지향 ?
- 성별 정체성 ?
- 출생 국가 (이주 배경) ?
- 아동기 경험 · 경제적 어려움 · 가정 생활 · 건강 상태 ?

NVIDIA: "성별 정체성의 경우
대표성 있는 공공 데이터가 없어 포함할 수 없었다."
(성적 지향 및 성별 정체성 관련 국가 통계 부재)

장애: 자료원에 있었음에도 스키마에 포함되지 않음

② 대규모 언어모델 (LLMs)

Llama 3.3 70B Instruct (1만 명),
GPT-6 Astra · Claude Opus 5
· Gemini 3.8 Flash (각 1천 명)

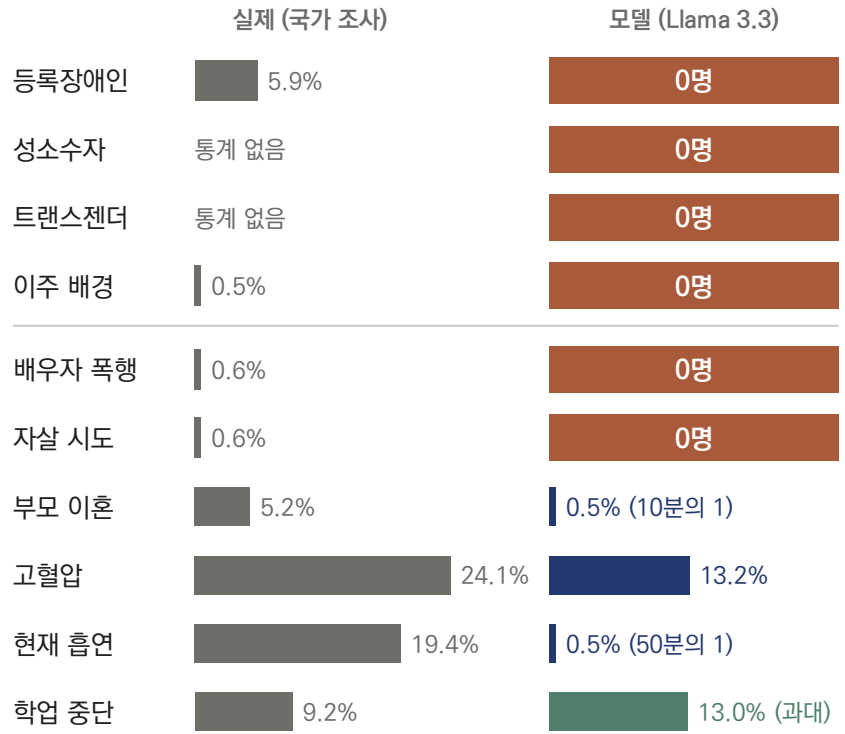
"당신은 한국에 살고 있는
다음의 인물입니다."
31문항 · 국가 조사 원문 그대로,
문항마다 그 사람으로서 이유를 쓰고
보기를 고름

빈칸을 만나면
학습 데이터에서 가장 흔한 값으로 채움:

비장애 · 이성애 · 시스젠더
국내 출생 · 건강 · 평온한 가정

(예측 오차 최소화 → 빈번한 패턴 보상)

③ 출력: 실제 한국인 vs. 모델이 만든 가상 한국인



주황색 = 0 (네 모델 공통) · 남색 = 과소 · 초록색 = 과대
성별·나이·학력·지역 분포는 국가 조사와 거의 일치

'부재' (데이터셋 스키마) + '채움' (모델 알고리즘) = 0 — 모델 안의 한국에는 장애인도, 이주민도, 성소수자도, 가정폭력 피해자도, 자살 시도자도 없다

페르소나를 적용한 대규모 언어모델은 입력된 페르소나의 빈칸을 규범적 기본값으로 채움으로써 소수자를, 사회적 고통을 지운다

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv

감사합니다

Kim et al., Architect of Silence: Persona-prompted Large Language Models Make Minority Population and Social Suffering Invisible, 2026, arXiv